Sieci neuronowe – ćwiczenie 1: raport

Zbiór: Heart Disease (UCI, id=45), 303 próbki, 13 cech. **Kod:** `lab1.py`. wykresy w folderze `wykresy/`.

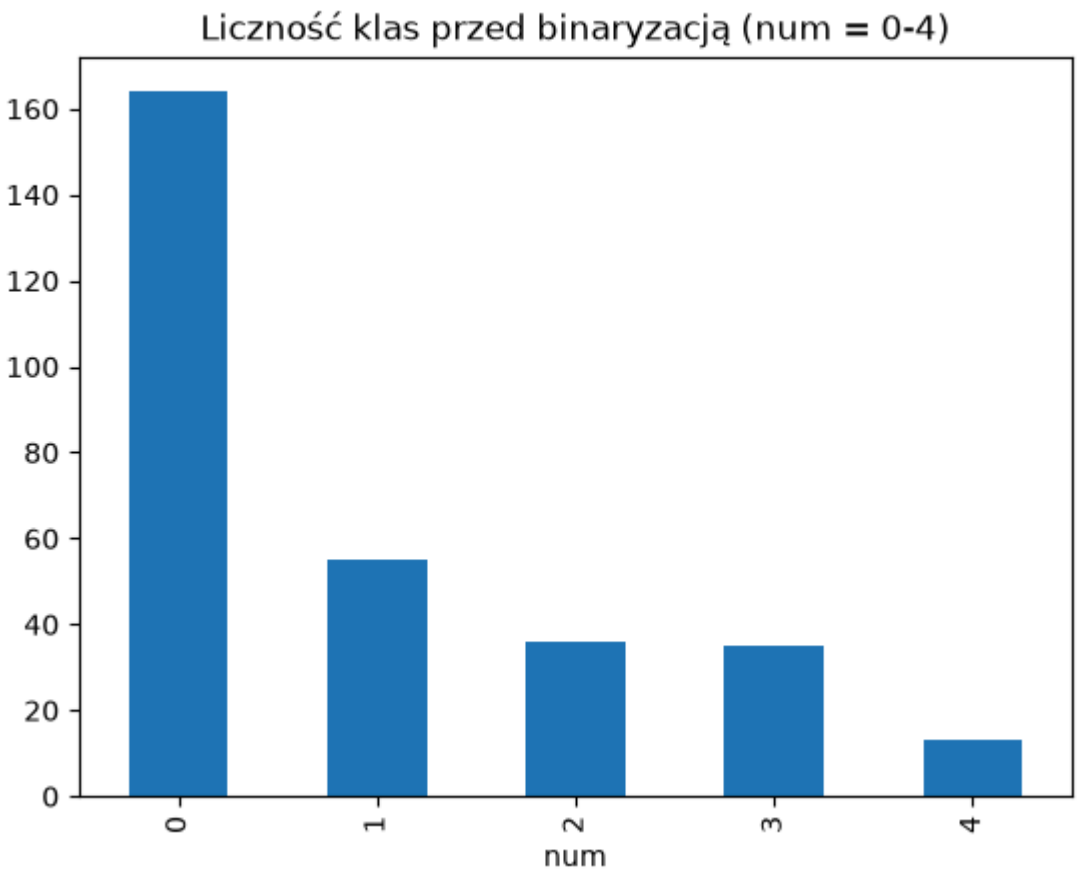
Podział cech:

- **liczbowe:** age, trestbps, chol, thalach, oldpeak
- **kategoryczne:** sex, cp, fbs, restecg, exang, slope, ca, thal

1. Czy zbiór jest zbalansowany?

Klasa (num)	0	1	2	3	4
Liczba próbek	164	55	36	35	13

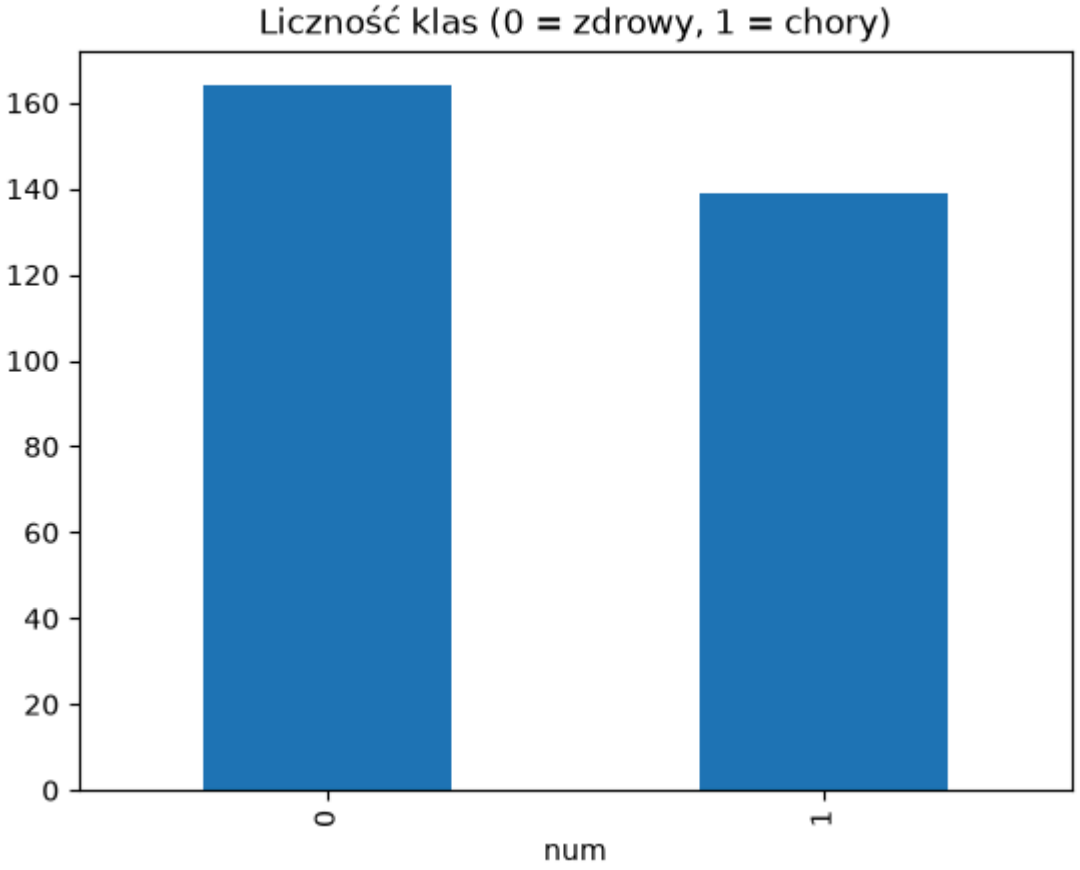
W oryginalnej postaci (5 klas) zbiór jest **niezbalansowany**, bo klasa 4 ma tylko 13 próbek.



Klasy 1–4 oznaczają różne stopnie choroby, więc łączymy je w jedną klasę „chory”:

Klasa	0 – zdrowy	1 – chory
Liczba próbek	164 (54%)	139 (46%)

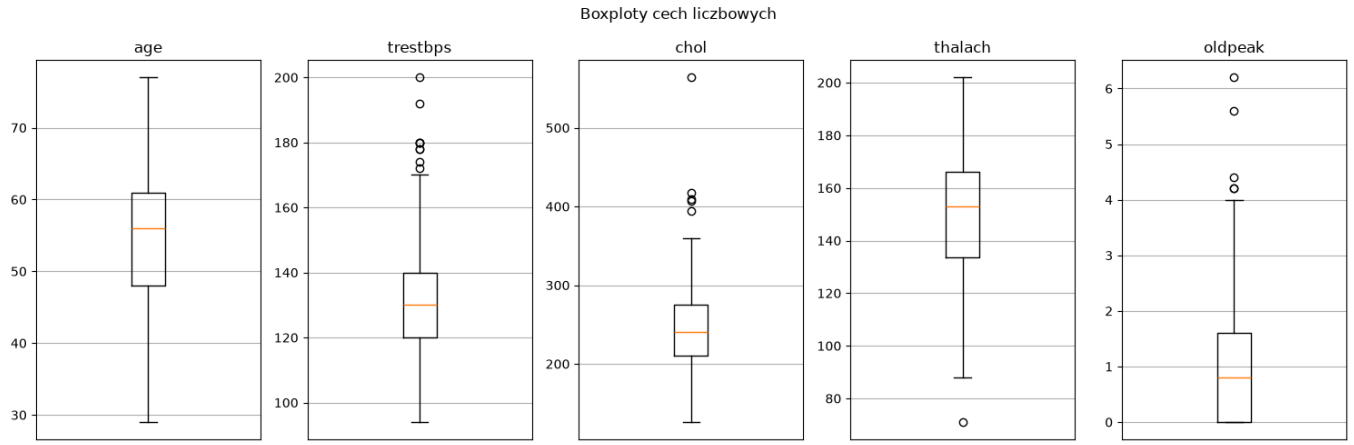
Po binaryzacji zbiór jest **w przybliżeniu zbalansowany**.



2. Średnie i odchylenia cech liczbowych

Cecha	Średnia	Odch. std.
age	54.44	9.04
trestbps	131.69	17.60
chol	246.69	51.78
thalach	149.61	22.88
oldpeak	1.04	1.16

Cechy mają bardzo różne skale (np. chol ok. 250, oldpeak ok. 1), więc trzeba je znormalizować. Widać to na boxplotach poniżej: każda cecha ma własną oś Y, a zakresy wartości są zupełnie różne (chol ok. 130–560, oldpeak ok. 0–6).

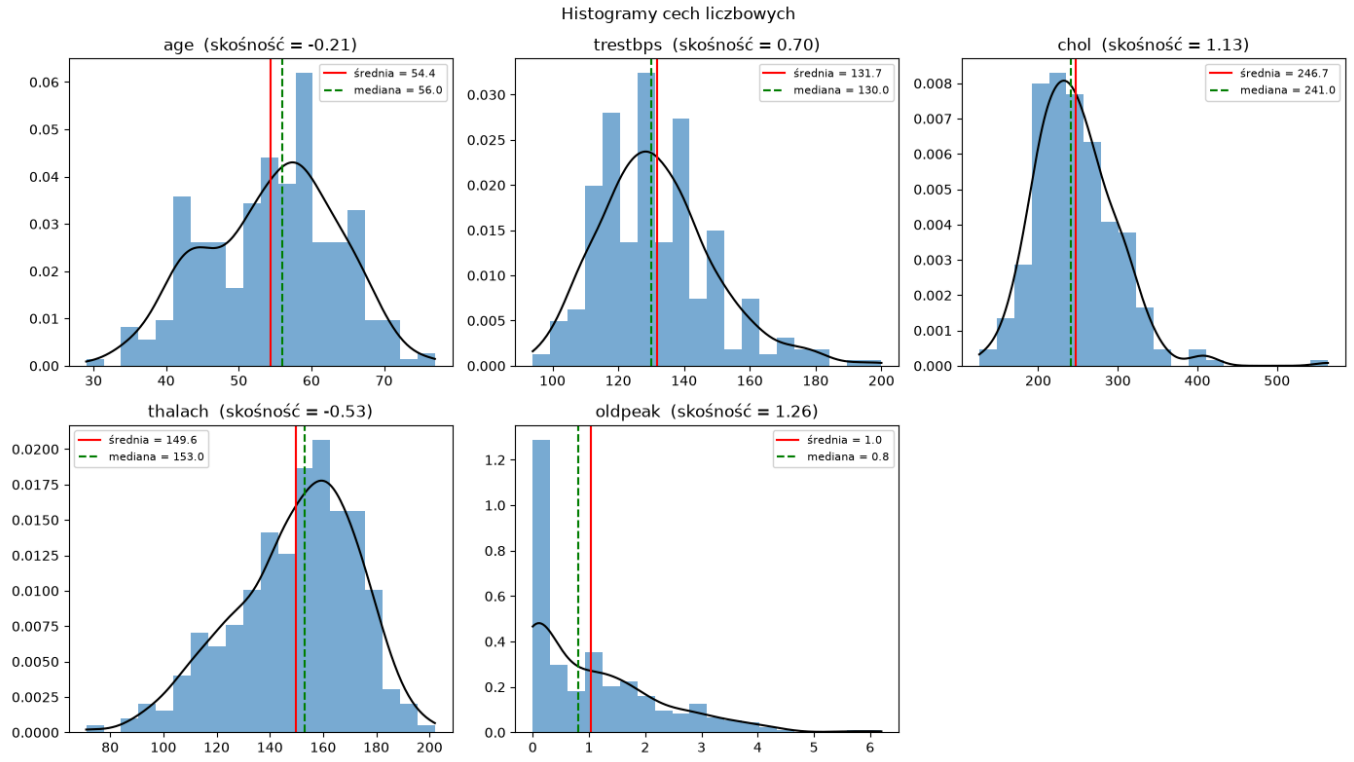


3. Czy cechy liczbowe mają rozkład normalny?

Test Shapiro-Wilka: dla wszystkich cech p < 0.05, więc formalnie **żadna nie ma rozkładu normalnego**. Na histogramy naniesiono krzywą gęstości (czarna), średnią (czerwona) i medianę (zielona przerywana).

Cecha	Średnia	Mediana	Skośność	Kształt
age	54.4	56.0	−0.21	prawie symetryczny, lekko lewoskośny
trestbps	131.7	130.0	0.70	prawoskośny
chol	246.7	241.0	1.13	prawoskośny (długi ogon do 564)
thalach	149.6	153.0	−0.53	lewoskośny
oldpeak	1.0	0.8	1.26	silnie prawoskośny, większość wartości = 0

Wniosek: age, trestbps, chol i thalach są **w przybliżeniu normalne**, ale **oldpeak wyraźnie nie jest normalny.**

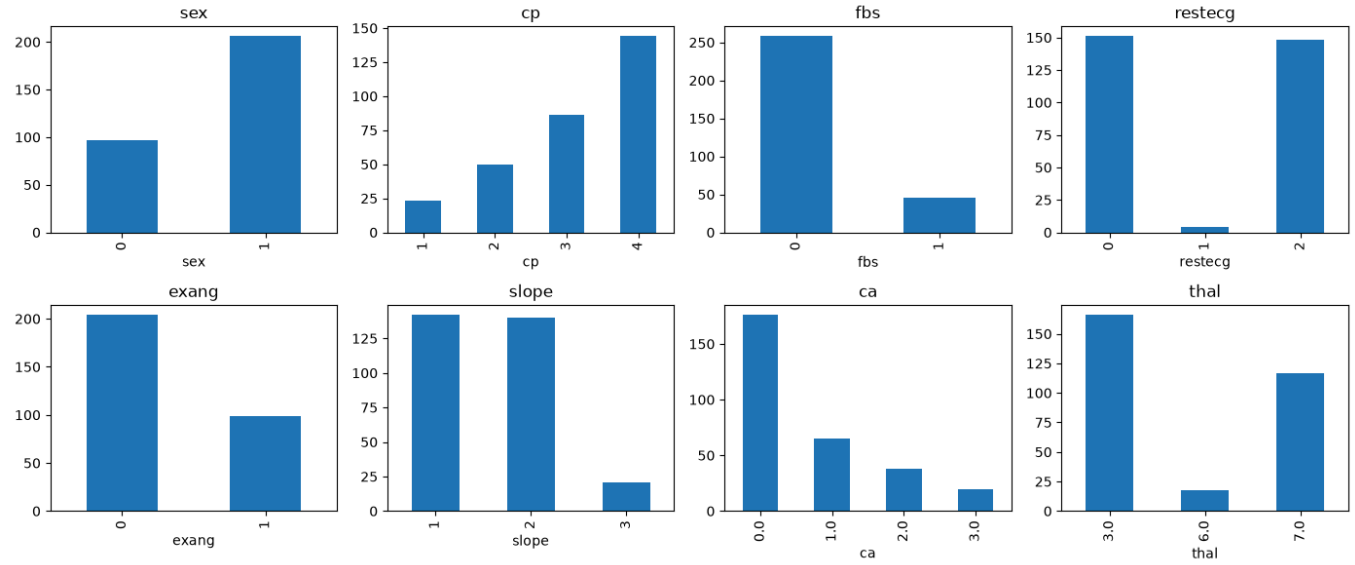


4. Czy cechy kategoryczne mają rozkład równomierny?

Test chi-kwadrat względem rozkładu równomiernego: dla wszystkich cech $p < 0.05$, więc **żadna nie ma rozkładu równomiernego**.

Cecha	Liczności kategorii
sex	0: 97, 1: 206
cp	1: 23, 2: 50, 3: 86, 4: 144
fbs	0: 258, 1: 45
restecg	0: 151, 1: 4, 2: 148
exang	0: 204, 1: 99
slope	1: 142, 2: 140, 3: 21
ca	0: 176, 1: 65, 2: 38, 3: 20
thal	3: 166, 6: 18, 7: 117

Najbardziej nierównomierne są fbs, restecg (kategoria 1 ma tylko 4 próbki) i thal.



5. Brakujące wartości

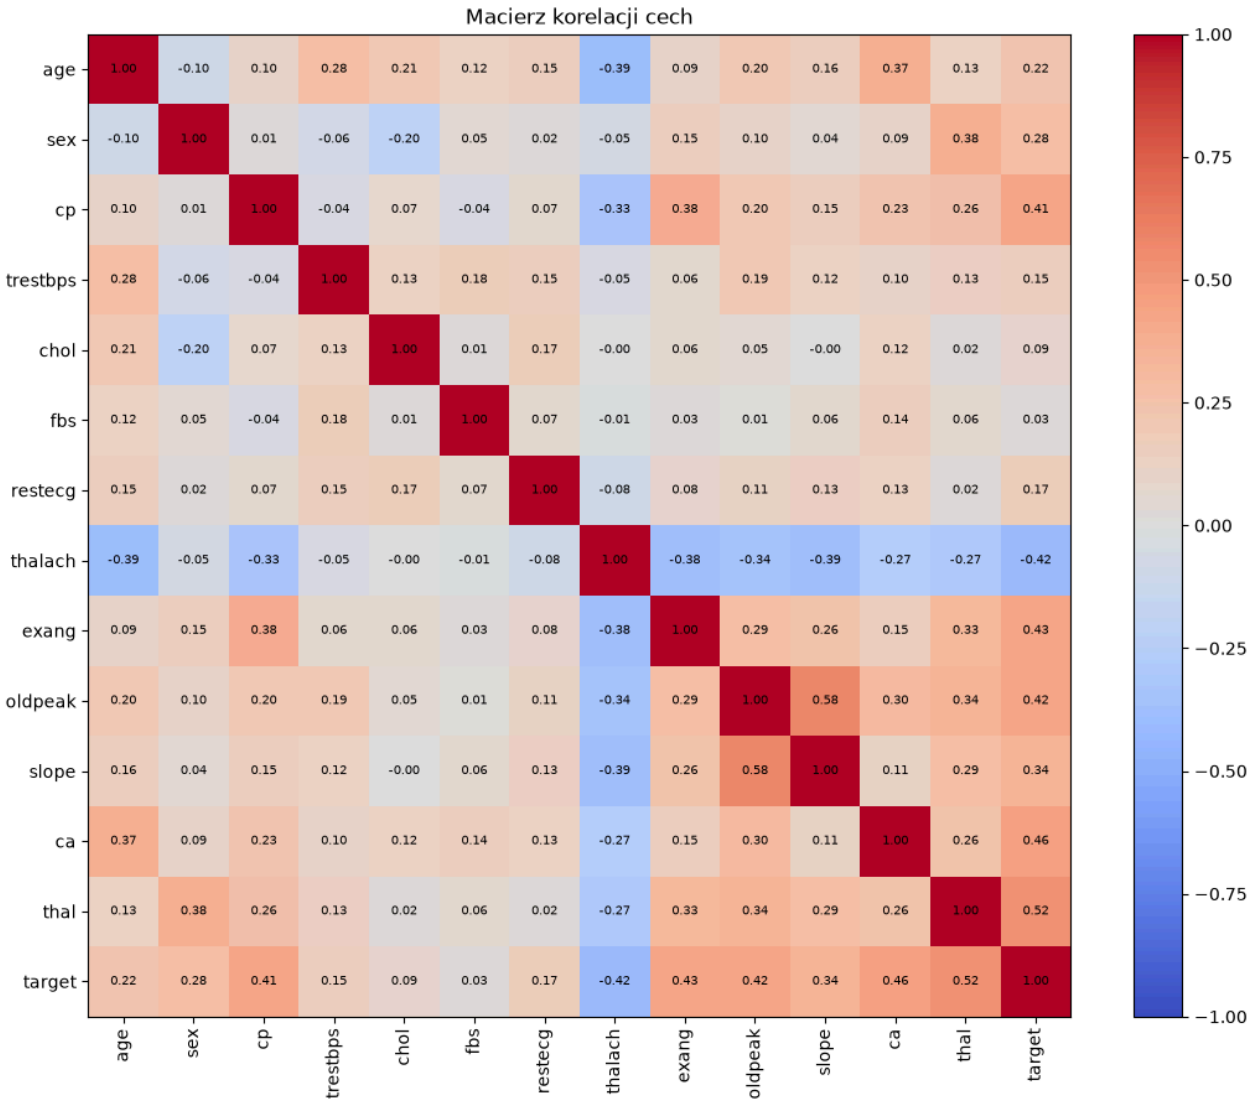
Cecha	Liczba braków
ca	4
thal	2

Braków jest tylko 6 (ok. 2% wierszy) i występują wyłącznie w cechach kategorycznych. Zastosowana strategia: **uzupełnienie dominantą**, czyli najczęstszą wartością (ca = 0, thal = 3). Inne możliwości to usunięcie tych 6 wierszy albo dodanie osobnej kategorii „brak”.

Macierz korelacji cech

Korelacja Pearsona od −1 do 1 między wszystkimi cechami i targetem (0 = zdrowy, 1 = chory). Czerwony kolor oznacza zależność dodatnią, a niebieski ujemną.

- **Najsilniej z targetem korelują:** thal (0.52), ca (0.46), exang (0.43), oldpeak (0.42), cp (0.41) i thalach (−0.42). Ujemny znak przy thalach oznacza, że niższe maksymalne tętno idzie w parze z chorobą.
- **Najsłabiej z targetem korelują:** fbs (0.03) i chol (0.09), więc mają mało informacji o klasie.
- **Między cechami** najsilniejsza zależność to oldpeak–slope (0.58). Żadna para nie przekracza ~0.6, czyli cechy nie są silnie redundantne.



6. Kodowanie i normalizacja

Klasyfikatory liniowe i sieci neuronowe wymagają liczb rzeczywistych o podobnej skali, dlatego:

1. **Cechy kategoryczne** → **one-hot encoding**: każda kategoria dostaje osobną kolumnę 0/1. Po kodowaniu mamy 28 cech.
2. **Podział train/test** w proporcji 80/20 ze stratyfikacją (242 / 61 próbek).
3. **Cechy liczbowe** → **standaryzacja** `(x − średnia) / odchylenie`. Parametry liczymy tylko na zbiorze treningowym, żeby nie przeciekała informacja ze zbioru testowego.

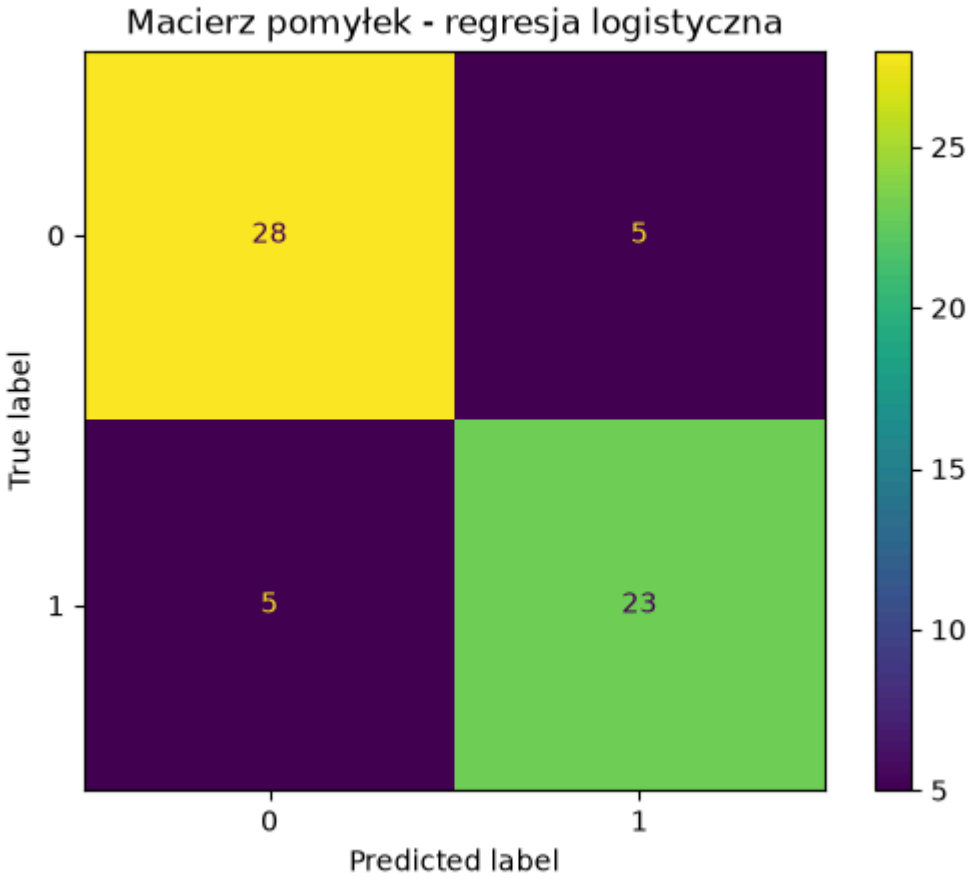
7. Baseline

Klasyfikator: **regresja logistyczna** (`sklearn.linear_model.LogisticRegression`), czyli prosty model liniowy.

Metryka	Wynik
Accuracy	**0.836**
F1-score	**0.821**

Macierz pomyłek (wiersze: prawdziwa klasa, kolumny: predykcja):

	pred. 0	pred. 1
zdrowy (0)	28	5
chory (1)	5	23



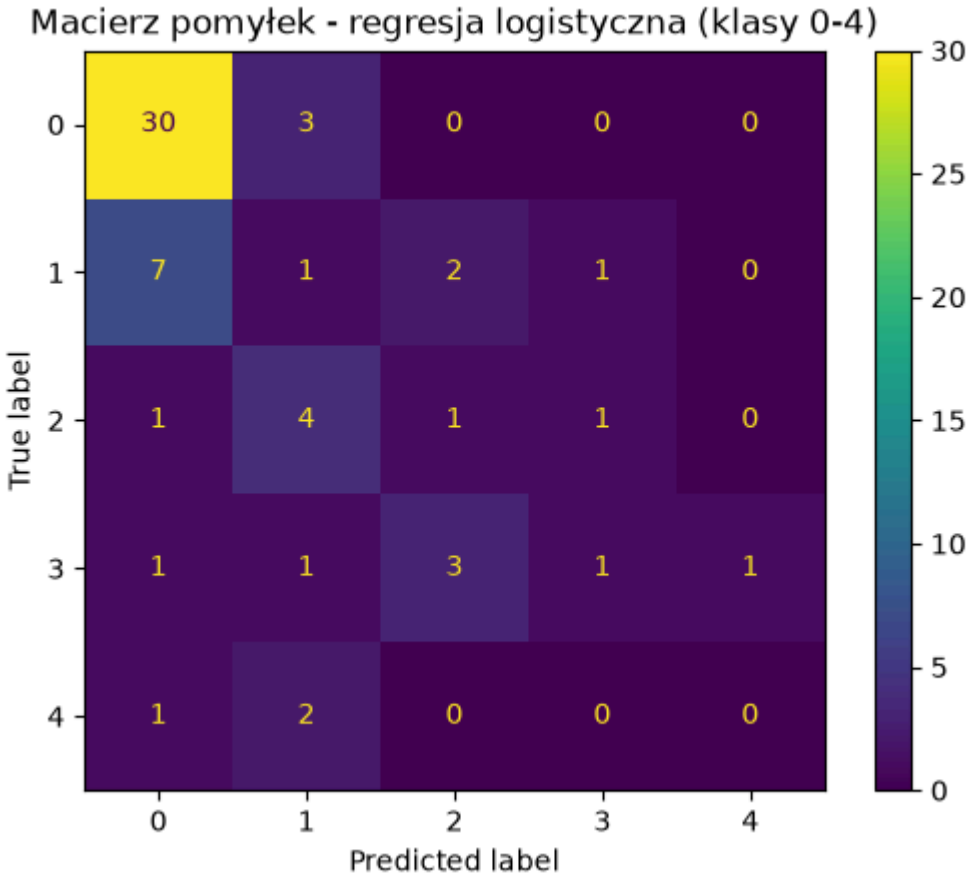
Baseline dla targetu przed binaryzacją (klasy 0–4)

Ten sam model i to samo przygotowanie danych, ale z oryginalnym targetem `num` (5 klas).

Metryka	Wynik
Accuracy	**0.541**
F1-score (macro)	**0.253**

	pred. 0	pred. 1	pred. 2	pred. 3	pred. 4
0	30	3	0	0	0
1	7	1	2	1	0
2	1	4	1	1	0
3	1	1	3	1	1
4	1	2	0	0	0

Klasę 0 model rozpoznaje dobrze (30 z 33). Klasy 1–4 mają w zbiorze testowym tylko 3–11 próbek i są często mylone ze sobą, a klasy 4 nie trafiono ani razu. Dlatego F1 macro jest niskie, a binaryzacja daje dużo lepszy i bardziej sensowny baseline.



Wnioski

- Po połączeniu klas 1–4 zbiór jest w przybliżeniu zbalansowany.
- Cechy liczbowe mają różne skale i nie są idealnie normalne, więc standaryzacja jest konieczna.
- Cechy kategoryczne są nierównomierne i zakodowano je metodą one-hot.
- Kilka braków (ca, thal) uzupełniono dominantą.
- **Baseline do dalszych porównań: accuracy ≈ 0.836 (regresja logistyczna, 2 klasy).** Dla 5 klas: accuracy ≈ 0.541, F1 macro ≈ 0.253.