Sieci neuronowe – ćwiczenie 2: raport

1. Dane i model

Przygotowanie danych jest takie samo jak w lab1:

- target binarny: 0 = zdrowy, 1 = chory
- braki uzupełnione dominantą
- cechy kategoryczne zakodowane one-hot (28 cech)
- cechy liczbowe standaryzowane
- podział 80/20, czyli 242 próbki treningowe i 61 testowych.

Model (wszystko zaimplementowane ręcznie w numpy):

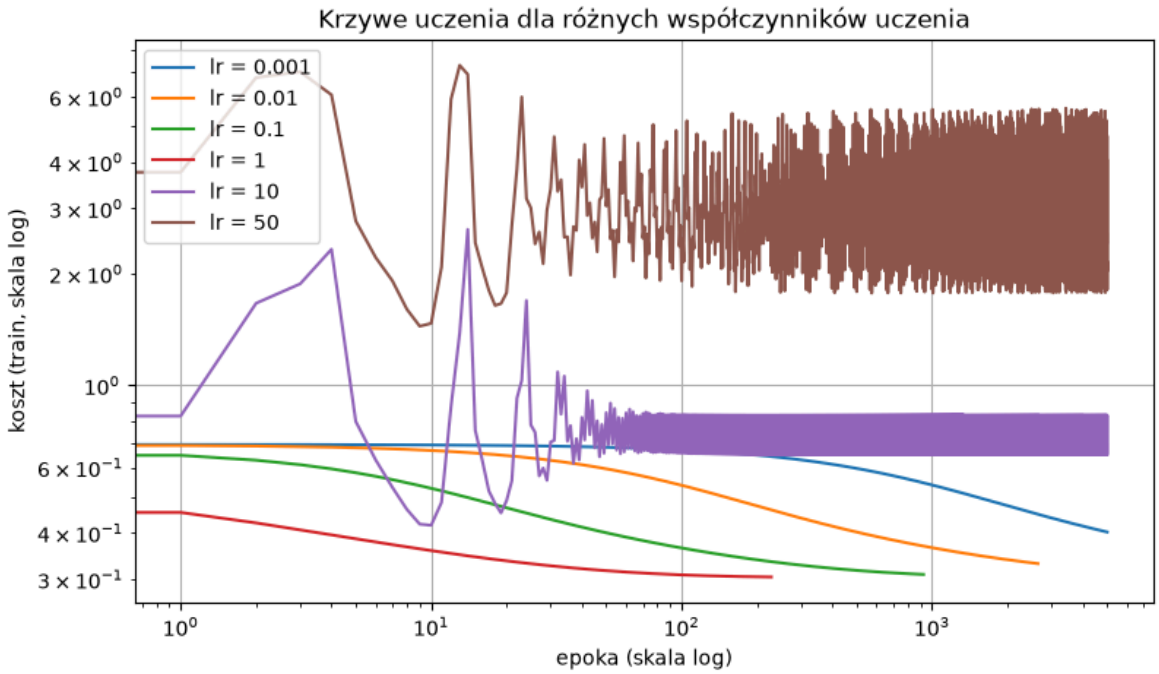
- wyjście: $p(x) = \sigma(Wx + b)$, gdzie $\sigma(z) = 1 / (1 + e^{-z})$
- koszt: entropia krzyżowa $L = -y \ln p - (1-y) \ln(1-p)$, uśredniona po próbkach
- gradient: $\partial L/\partial w_i = -(y - p(x))\, x_i$
- aktualizacja wag: $w_i \leftarrow w_i - \alpha \cdot \partial L/\partial w_i$. W każdej epoce liczymy gradient na całym zbiorze treningowym
- warunek stopu: przerywamy, gdy koszt zmieni się o mniej niż tol między epokami

Metryki precision, recall i F1 liczone są na zbiorze testowym, przy progu klasyfikacji 0.5.

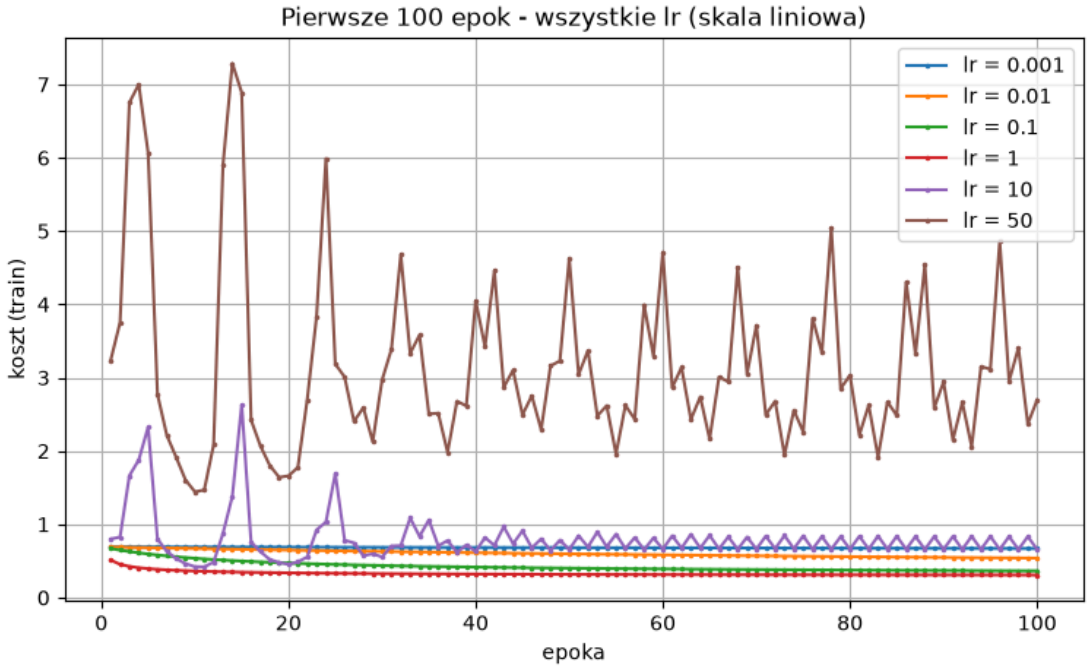
2. Wpływ współczynnika uczenia (α)

Inicjalizacja wag: zera. Stop przy tol = 1e-5, maksymalnie 5000 epok.

α	Epoki do zbieżności	Koszt końcowy (train)	F1	Precision	Recall
0.001	5000 (nie zbiegł)	0.402	0.815	0.846	0.786
0.01	2647	0.331	0.836	0.852	0.821
0.1	925	0.309	0.836	0.852	0.821
1	**229**	**0.304**	0.828	0.800	0.857
10	5000 (oscyluje)	0.651	0.765	0.650	0.929
50	5000 (oscyluje)	2.141	0.769	0.833	0.714



Pierwsze 100 epok w skali liniowej, z kosztem w każdej epoce:



- **Za małe α (0.001, 0.01):** koszt cały czas spada w dobrą stronę, ale bardzo wolno. Przy α = 0.001 model nie zdążył zbiec w 5000 epokach. Problem tylko **przedłuża uczenie**.

  Linia α = 0.001 kończy się na wykresie w epoce 5000, bo zatrzymał ją limit epok, a nie warunek stopu. Gdy uczono ją dalej, bez limitu, koszt spadał tak:

Epoka	Koszt train
5 000	0.402 (koniec na wykresie)
10 000	0.365
20 000	0.339
50 000	0.317
~92 400	0.309 (tyle co α = 0.1 po 925 epokach)

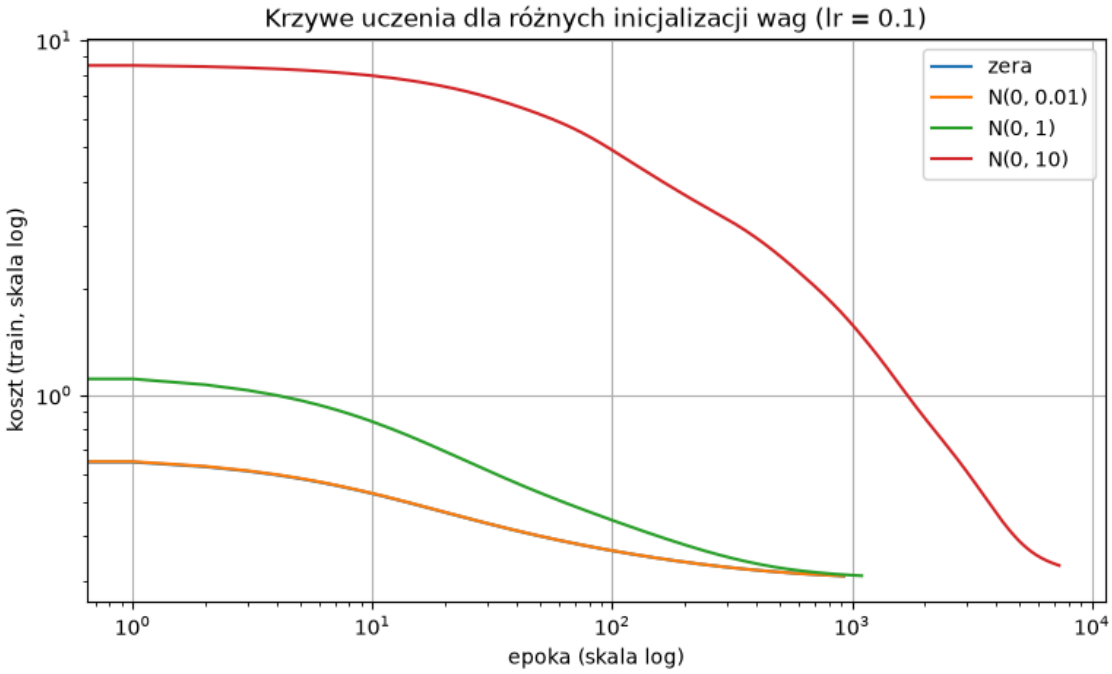
Model z α = 0.001 dochodzi więc do tego samego minimum co pozostałe, tylko potrzebuje ok. **100 razy więcej epok** niż α = 0.1.

- **Dobre α (0.1–1):** szybka i gładka zbieżność do minimum kosztu ≈ 0.304–0.309.
- **Za duże α (10, 50):** krok jest tak duży, że model „przeskakuje" minimum. Koszt skacze i nigdy się nie ustabilizuje.

3. Wpływ inicjalizacji wag

α = 0.1, stop przy tol = 1e-5.

Inicjalizacja	Epoki	Koszt początkowy	Koszt końcowy	F1
zera	925	0.669	0.309	0.836
N(0, 0.01)	925	0.671	0.309	0.836
N(0, 1)	1098	1.155	0.310	0.836
N(0, 10)	7309	8.551	0.331	0.800



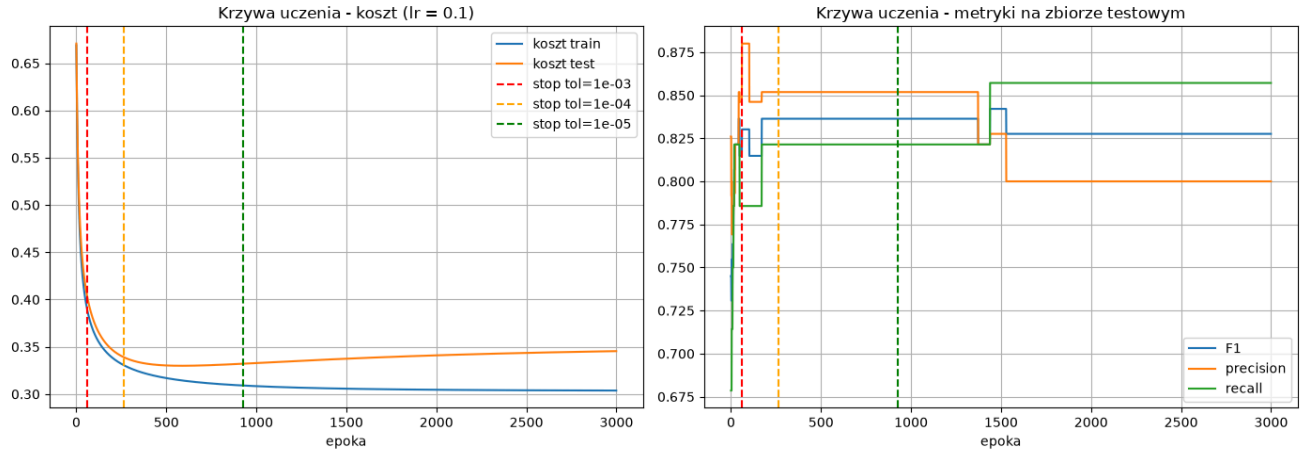
- Zera i małe losowe wagi dają praktycznie identyczny przebieg.

- **Duże wagi początkowe (N(0, 10))** sprawiają, że na starcie model jest bardzo pewny złych odpowiedzi, a koszt wynosi 8.55. Uczenie trwa wtedy ok. 8 razy dłużej.
- Warunek stopu zatrzymał N(0, 10) przy koszcie 0.331, a nie 0.309, bo koszt spadał już powoli. Gdy uczenie przedłużono (tol = 1e-7), model z N(0, 10) doszedł do kosztu **0.304**, czyli do tego samego minimum co pozostałe.
- Wniosek: zła inicjalizacja w modelu liniowym **tylko przedłuża uczenie**. Funkcja jest wypukła, więc każdy start prowadzi do tego samego globalnego minimum.

4. Liczba epok i warunek stopu: krzywa uczenia

α = 0.1, inicjalizacja zerami, 3000 epok bez warunku stopu. Przerywane linie pokazują, gdzie zatrzymałyby uczenie różne warunki stopu.

tol	Stop po epokach	Koszt test	F1
1e-3	59	0.406	0.815
1e-4	265	0.339	0.836
1e-5	925	0.332	0.836



- **Koszt na zbiorze treningowym** spada przez cały czas, coraz wolniej.
- **Koszt na zbiorze testowym** jest najmniejszy około epoki 588 (0.330), a potem powoli rośnie (0.345 po 3000 epokach). To lekkie **przeuczenie**: model coraz lepiej dopasowuje się do zbioru treningowego kosztem testowego.
- **Metryki** (F1, precision, recall) ustalają się już po ok. 200 epokach. Dalsze uczenie prawie ich nie zmienia, a po ~1500 epokach F1 nawet lekko spada (0.836 → 0.828).
- **Warunek stopu:**
  - tol = 1e-3 zatrzymuje uczenie za wcześnie i model jest niedouczony;
  - tol = 1e-4 i 1e-5 dają dobry wynik;
  - zbyt długie uczenie nic nie daje, a nawet lekko szkodzi.

5. Wynik końcowy

Model: α = 0.1, inicjalizacja zerami, tol = 1e-5 (925 epok).

Metryka	Własna regresja logistyczna	Baseline sklearn (lab1)
Accuracy	0.852	0.836
Precision	0.852	–
Recall	0.821	–
F1	**0.836**	0.821

Własna implementacja osiąga wynik porównywalny z `LogisticRegression` ze scikit-learn, a nawet nieco lepszy.

Wnioski: czy klasyfikator liniowy zawsze zbiega do globalnego minimum?

- **Funkcja kosztu regresji logistycznej jest wypukła**, więc nie ma minimów lokalnych, w których gradient mógłby „utknąć". Przy rozsądnych parametrach model zawsze do niego dochodzi, niezależnie od startu: wszystkie udane przebiegi kończą z kosztem ≈ 0.304–0.31 i F1 ≈ 0.83.
- **Mogą jednak pojawić się problemy przez złą parametryzację:**
    - **za duży współczynnik uczenia** ($\alpha \geq 10$) **całkowicie uniemożliwia zbieżność**: koszt oscyluje i jakość jest wyraźnie gorsza;
    - **za mały współczynnik uczenia** i **zła (duża) inicjalizacja tylko przedłużają uczenie**: model dalej dąży do tego samego minimum, ale potrzebuje wielokrotnie więcej epok;
    - **zły warunek stopu** może przerwać uczenie za wcześnie (niedouczenie). Za późny stop marnuje czas, a na danych testowych daje lekkie przeuczenie.